UNIVERZITET U BEOGRADU
ELEKTROTEHNIČKI FAKULTET



Modeli mašinskog učenja za unutrašnje pozicioniranje korisnika primenom RSSI signala WiFi pristupnih tačaka

SEMINARSKI RAD

Predmet: Slučajni procesi u telekomunikacijama

Mentor:

Prof. Dr Predrag Ivaniš

Kandidat:

Danica Čolić 2022/0437

Nemanja Vasić 2021/0401

Beograd, 2026.

1.Uvod 4
2. Teorijska obrada 6
2.1. kNN 6
2.2. Neural network 7
2.3. Support Vector Machine 8
2.4. Quadratic Discriminant Analysis 9
2.5. Expectation Maximization 10
3. Eksperimantalna evaluacija i materijali 13
3.1. Materijali 14
3.2. Primena Expectation Maximization 14
3.3. Zamena nepoznatih vrednosti 16
3.4. Segmentacija 17
3.4.1. Prva segmentacija 17
3.4.2. Druga segmentacija 19
3.5. QDA implementacija 20
4. Rezultati i diskusija 21
4.1. k-Nearest Neighbors rezultati 21
4.2. Neuralna mreža rezultati 23
4.2.1. Izbor klasifikatora 23
4.2.2. Arhitektura regresora 25
4.2.3. Izbor Regularizacije L2 26
4.2.4. Izbor Batch size 26
4.2.5. Uticaj broja slojeva kod regresije na vreme izvršavanja 27
4.2.6. Rezultati 28
4.3. Support Vector Machine 31
4.3.1. Izbor regularizacije 31
4.3.2. Izbor kernela 31
4.3.2. Izbor gamme 32
4.3.3. Izbor clippinga 32
4.3.4. Rezultati 32
4.4. Diskusija 34
5. Zaključak 36

1.Uvod

Savremeni sistemi za unutrašnje pozicioniranje (eng. indoor localization) suočavaju se sa brojnim izazovima usled refleksije signala, prigušenja kroz zidove i opšteg dinamičkog okruženja unutar objekata. Jedan od najrasprostranjenijih pristupa rešavanju ovog problema jeste korišćenje indikatora jačine primljenog signala (eng. Received Signal Strength Indicator – RSSI) sa postojećih WiFi pristupnih tačaka (AP). Cilj ovog projekta je razvoj i evaluacija modela mašinskog učenja za potrebe precizne lokalizacije korisnika unutar prostora fakulteta.

Eksperimentalna baza podataka obuhvata ukupno 1612 merenja prikupljenih na 403 fizičke lokacije unutar pravougaone površine dimenzija 147.1 m × 66.1 m. Na svakoj lokaciji izvršena su po 4 merenja koja odgovaraju različitim orijentacijama antene (0°, 90°, 180°, 270°) u odnosu na 8 WiFi pristupnih tačaka. Ključni izazov u ovom radu predstavlja izrazito visok procenat nedetektovanih signala sa pristupnih tačaka, koji se kreće od 59% (za AP4) pa sve do 83% (za AP2). Sa prosekom od svega 2.38 detektovanih od mogućih 8 pristupnih tačaka po uzorku, problem se klasifikuje kao izrazito širok, jer je većina ulaznog vektora nepoznata.

U okviru ovog rada primenjene su i upoređene tri popularne tehnike mašinskog učenja: metoda k-najbližih komšija (kNN), veštačke neuronske mreže (NN) i metoda potpornih vektora (SVM). Rad analizira uticaj različitih strategija za rukovanje nedostajućim vrednostima (poput Expectation Maximization metode i konstantne zamene), kao i uticaj segmentacije prostora na ukupnu tačnost klasifikacije zona i smanjenje srednje kvadratne greške (RMSE) pozicioniranja.

2. Teorijska obrada

U ovom poglavju će biti opisani korišćene metode mašinskog učenje. Te metode su k-Nearest Neighbors, neural network, Support Vector Machine, kao i Quadratic Discriminant Analysis i Expectation Maximization.

2.1. kNN

Algoritam k-najbližih suseda (kNN) predstavlja jedan od najjednostavnijih i najintuitivnijih metoda u domenu superviziranog mašinskog učenja. Za razliku od algoritama kao što je SVM, koji eksplicitno grade model tokom faze obuke, kNN se klasifikuje kao "lenji" (lazy) algoritam. Ovo znači da on ne vrši nikakvu generalizaciju podataka pre samog procesa predviđanja; umesto toga, čitav trening skup se čuva u memoriji i koristi direktno u trenutku kada treba klasifikovati novi, nepoznati primer.

Osnovna ideja kNN algoritma zasniva se na pretpostavci da podaci koji su slični po svojim karakteristikama zauzimaju blizak prostor u višedimenzionalnom prostoru obeležja. Proces klasifikacije novog podatka odvija se kroz tri ključna koraka:

- **Izbor metrike rastojanja:** Neophodno je definisati način na koji se meri "bliskost" između dve tačke. Najčešće korišćena metrika je Euklidsko rastojanje, mada se u zavisnosti od tipa podataka mogu primeniti i druge mere, poput Menhetn ili Kosinusnog rastojanja.
- **Identifikacija K najbližih suseda:** Algoritam izračunava udaljenost novog primera od svih tačaka u trening skupu i identifikuje tačaka koje su mu prostorno najbliže. Izbor parametra je od presudnog značaja za performanse modela; suviše mali čini model osetljivim na šum, dok suviše veliki može dovesti do brisanja granica između klasa.
- **Odlučivanje glasanjem:** Nakon identifikacije suseda, algoritam vrši klasifikaciju većinskim glasanjem. Novi podatak dobija oznaku klase koja je najzastupljenija među odabranih suseda. U slučaju regresije, predviđena vrednost se obično računa kao prosek vrednosti tih suseda.

Glavna prednost kNN-a leži u njegovoj jednostavnosti implementacije i činjenici da ne zahteva pretpostavke o distribuciji podataka. Kako se novi podaci dodaju u sistem, model se automatski ažurira bez potrebe za ponovnim treniranjem.

Međutim, algoritam poseduje značajna ograničenja u pogledu skalabilnosti. Kako veličina trening skupa raste, računski zahtevi za izračunavanje udaljenosti od svakog primera postaju izuzetno veliki, što čini predviđanje sporim. Takođe, kNN je veoma osetljiv na nejednake skale obeležja, zbog čega je standardizacija ili normalizacija podataka pre primene algoritma obavezna procedura.

2.2. Neural network

Veštačke neuronske mreže (ANN) predstavljaju računarski model inspirisan strukturom i funkcionisanjem bioloških nervnih sistema. Osnovna jedinica mreže je veštački neuron (perceptron), koji prima ulazne signale, ponderiše ih, sumira i propušta kroz nelinearnu aktivacionu funkciju. Mreže su organizovane u slojeve: ulazni sloj koji prihvata sirove podatke, jedan ili više skrivenih slojeva gde se vrši ekstrakcija karakteristika, i izlazni sloj koji daje konačnu predikciju.

Za razliku od kNN ili SVM modela, neuronske mreže uče putem iterativnog procesa optimizacije težinskih koeficijenata. Proces se odvija kroz tri ključne faze:

- **Propagacija unapred (Forward Propagation):** Ulazni podaci prolaze kroz mrežu, gde se na svakom neuronu vrši množenje težinama i primena aktivacione funkcije. Rezultat je izlazna vrednost mreže.
- **Izračunavanje gubitka:** Dobijeni rezultat se upoređuje sa stvarnom vrednošću putem funkcije gubitka (loss function), koja kvantifikuje grešku modela.
- **Propagacija unazad (Backpropagation):** Ovo je srce procesa učenja. Algoritam koristi gradijentni spust kako bi se greška propagirala unazad kroz mrežu, prilagođavajući težine svih neurona tako da se minimizuje ukupna greška.

Efikasnost neuronskih mreža zavisi od nekoliko tehničkih izbora:

- **Aktivacione funkcije:** Nelinearne funkcije kao što su ReLU, Sigmoid ili Tanh omogućavaju mreži da modeluje kompleksne, nelinearne zavisnosti u podacima, što je osnovni preduslov za rešavanje složenih problema.
- **Arhitektura:** Broj slojeva i broj neurona po sloju određuju kapacitet mreže. Duboke neuronske mreže (Deep Learning) poseduju veliki broj skrivenih slojeva, što im omogućava hijerarhijsko učenje apstraktnih koncepata.
- **Hiperparametri:** Brzina učenja (learning rate), veličina paketa (batch size) i broj epoha su parametri koje definiše korisnik, a koji direktno utiču na stabilnost i brzinu konvergencije tokom procesa obuke.

Neuronske mreže nude izuzetnu fleksibilnost i sposobnost modelovanja veoma kompleksnih funkcija, čineći ih standardom za zadatke prepoznavanja slika, obrade prirodnog jezika i prediktivne analitike velikih razmera. Za razliku od SVM-a koji se fokusira na pronalaženje optimalne granice, neuronske mreže iterativno "uče" unutrašnju reprezentaciju podataka, čime postižu superiorne performanse u situacijama sa ogromnim količinama nestrukturiranih informacija.

2.3. Support Vector Machine

Algoritam Podrška vektorskim mašinama (SVM) predstavlja metod superviziranog mašinskog učenja namenjen klasifikaciji podataka. Osnovni cilj SVM-a je pronalaženje optimalne hiperravni koja razdvaja primere različitih klasa uz maksimalizaciju margine. Margina se definiše kao razmak između hiperravni i najbližih tačaka iz svake klase, koje se nazivaju vektori podrške. Matematička formulacija optimizacionog procesa zasniva se na minimizaciji funkcije , što omogućava primenu metoda kvadratnog programiranja radi pronalaženja optimalnog rešenja.

U praktičnim primenama, podaci često nisu savršeno odvojivi linearnom granicom, što zahteva dodatnu obradu:

- **Upravljanje šumom i autlajerima:** U situacijama kada prisustvo šuma ili pogrešno označenih podataka onemogućava postojanje savršene hiperravni, SVM koristi koncept "meke margine". Ovaj pristup dozvoljava određeno odstupanje pojedinačnih primera od idealne granice, čime se postiže balans između širine margine i tolerancije na greške u trening skupu.
- **Nelinearna separabilnost:** Za podatke čija se struktura ne može adekvatno predstaviti pravom linijom ili ravni, SVM primenjuje mapiranje podataka u prostor veće dimenzije. Kroz ovaj postupak, podaci koji su u početnom prostoru nelinearno raspoređeni postaju linearno odvojivi u transformisanom prostoru višeg reda. Time se omogućava formiranje kompleksnih granica odlučivanja, poput kružnih ili eliptičnih oblika, koristeći linearne metode u višedimenzionalnom prostoru.

SVM integriše geometrijsku rigoroznost sa sposobnošću adaptacije na složene setove podataka. Kroz optimizaciju margine, rukovanje šumom putem meke margine i primenu transformacija u prostore višeg reda, algoritam obezbeđuje visoku preciznost i generalizacionu moć u širokom spektru klasifikacionih problema.

2.4. Quadratic Discriminant Analysis

Kvadratna diskriminantna analiza (QDA) je klasifikacioni model zasnovan na verovatnoći koji pretpostavlja da podaci unutar svake klase prate normalnu (Gausovu) raspodelu. Za razliku od Linearne diskriminantne analize (LDA), koja pretpostavlja da sve klase dele istu kovarijacionu matricu, QDA dozvoljava svakoj klasi da ima sopstvenu kovarijacionu matricu. Ova fleksibilnost omogućava modelu da modeluje kompleksnije, nelinearne granice između klasa.

Osnova QDA modela leži u Bejsovom pravilu, gde se klasa novog primera određuje na osnovu posteriorne verovatnoće. S obzirom na pretpostavku o normalnoj raspodeli podataka, funkcija diskriminacije za svaku klasu je kvadratnog oblika u odnosu na ulazne promenljive.

- **Fleksibilnost kovarijacije:** Kako svaka klasa poseduje sopstvenu matricu kovarijacije, model se prilagođava različitim oblicima i orijentacijama raspodela klasa u prostoru obeležja. Ovo je ključna razlika koja QDA čini sposobnom da formira eliptične ili druge kvadratne granice odlučivanja.
- **Proces klasifikacije:** Za dati ulazni vektor, QDA izračunava verovatnoću pripadnosti svakoj klasi, a zatim dodeljuje primer klasi sa najvećom izračunatom verovatnoćom.

QDA nudi specifičan balans između preciznosti modela i broja parametara:

- **Sposobnost modelovanja nelinearnosti:** Zahvaljujući kvadratnom članu u jednačini granice, QDA može uspešno razdvojiti klase koje nisu linearno odvojive, što je čini nadmoćnijom u odnosu na LDA u slučajevima kada su raspodele klasa značajno različite.
- **Problem dimenzionalnosti:** Najveće ograničenje QDA modela je broj parametara koji se moraju proceniti. Budući da se za svaku klasu procenjuje zasebna kovarijaciona matrica, broj parametara raste kvadratno u odnosu na broj obeležja. To može dovesti do preprilagođavanja (overfitting) ukoliko trening skup nije dovoljno veliki u odnosu na broj dimenzija.

QDA predstavlja moćan alat kada postoji sumnja da klase imaju različitu varijansu ili strukturu kovarijacije. Iako je matematički složeniji od linearnih metoda, pruža neophodnu fleksibilnost za identifikaciju nelinearnih granica, pod uslovom da postoji dovoljno podataka za pouzdanu procenu statističkih parametara svake klase.

2.5. Expectation Maximization

Expectation-Maximization (EM) je iterativni optimizacioni algoritam koji se koristi za pronalaženje procena maksimalne verovatnoće parametara statističkih modela u situacijama kada postoje skrivene (latentne) promenljive ili podaci koji nedostaju. Algoritam funkcioniše kroz ponavljanje dva ključna koraka:

- **E-korak (Expectation):** Procenjuje se očekivana vrednost logaritamske verovatnoće (log-likelihood) na osnovu trenutnih procena parametara i dostupnih podataka. Praktično, ovde se "popunjavaju" nedostajuće vrednosti ili procenjuje verovatnoća pripadnosti latentnim grupama.
- **M-korak (Maximization):** Ažuriraju se parametri modela tako da maksimizuju očekivanu verovatnoću dobijenu u E-koraku.

Ovaj proces se ponavlja sve dok se parametri ne stabilizuju, odnosno dok algoritam ne konvergira ka lokalnom maksimumu.

Za validnu primenu EM algoritma u kontekstu podataka koji nedostaju, ključno je razumeti mehanizam njihovog izostanka. Prema Rubin-ovoj klasifikaciji, podaci koji nedostaju moraju biti **MAR (Missing At Random)** da bi EM algoritam dao nepristrasne procene.

- **Definicija MAR:** Podaci su MAR ako verovatnoća da podatak nedostaje ne zavisi od same vrednosti koja nedostaje, već isključivo od vrednosti koje su već poznate (posmatrane).
- **Zašto je ovo neophodno:** Ako podaci nisu MAR (npr. ako su MNAR - Missing Not At Random, gde izostanak direktno zavisi od nepoznate vrednosti), EM algoritam će

koristiti pretpostavljenu distribuciju za popunjavanje podataka koja nije validna. To dovodi do sistemske pristrasnosti u proceni parametara, jer model ne može "videti" pravu strukturu podataka koja je skrivena samim mehanizmom izostanka.

- **Implikacija za EM:** Kada je ispunjen uslov MAR, EM algoritam efikasno koristi sve dostupne informacije iz posmatranih podataka kako bi "inferirao" one koji nedostaju, čime se dobija robusniji model nego što bi to bilo moguće metodama poput proste eliminacije nepotpunih zapisa.

EM algoritam je široko primenjen u modelima sa mešavinom Gausovih raspodela (GMM), gde se latentne promenljive koriste za identifikaciju klastera unutar podataka.

Glavni izazovi rada sa ovim algoritmom su:

1. **Konvergencija ka lokalnom optimumu:** Rezultat algoritma može zavisiti od početnih vrednosti parametara.
2. **Računska kompleksnost:** U zavisnosti od složenosti modela, E i M koraci mogu biti intenzivni, posebno sa velikim setovima podataka.
3. **Zavisnost od pretpostavke mehanizma:** Ako se prekrši pretpostavka o MAR mehanizmu, model gubi svoju statističku validnost.

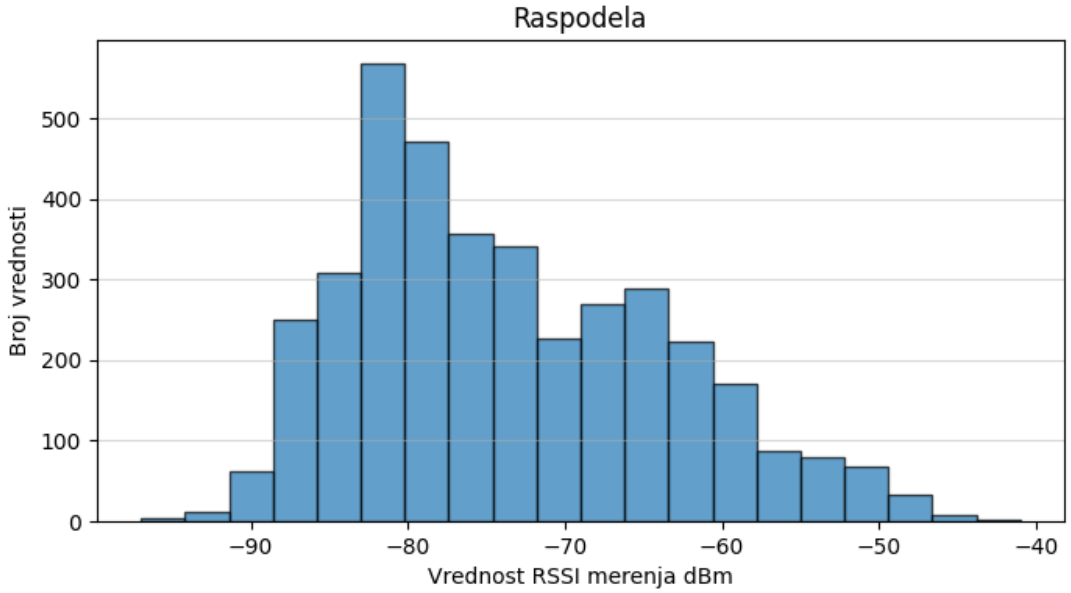
EM algoritam je nezamenljiv alat za rad sa nepotpunim informacijama, pod uslovom da je mehanizam izostanka podataka MAR. Njegova sposobnost da integriše skrivene promenljive u optimizacioni proces čini ga superiornim u odnosu na klasične statističke metode u scenarijima gde podaci nisu kompletni, pod uslovom da se pretpostavke o distribuciji podataka pažljivo evaluiraju pre početka procesa.

3. Eksperimantalna evaluacija i materijali

U ovom poglavlju će biti opisana baza podataka, kao i parametri koji su korišćeni pri treniranju kNN, neuralne mreže i SVM. Govoriće se i primeni metode Expectation Maximization na bazi podataka kao i primeni QDA.

3.1. Materijali

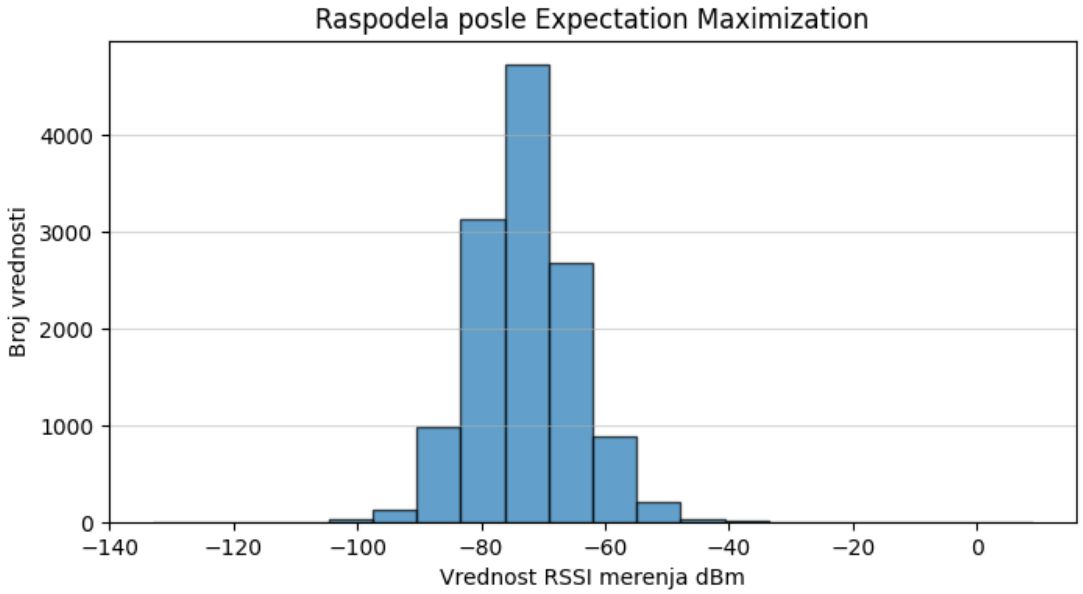
Baza RSSI_Database.xls sadrži 1612 merenja, izmerenih u indoor okruženju na osnovu izmerenih RSSI vrednosti sa 8 WiFi pristupnih tačaka, prikupljenih na 403 fizičke lokacije. Svaka lokacija ima po 4 merenja koja odgovaraju četiri orijentacije antene (0°, 90°, 180°, 270°). Prostor pokriva pravougaonu povrsinu dimenzija 147.1 m × 66.1 m. Karakteristika ovog dataseta je visok procenat nedetektovanih AP-ova (od 59% za AP4 do 83% za AP2).



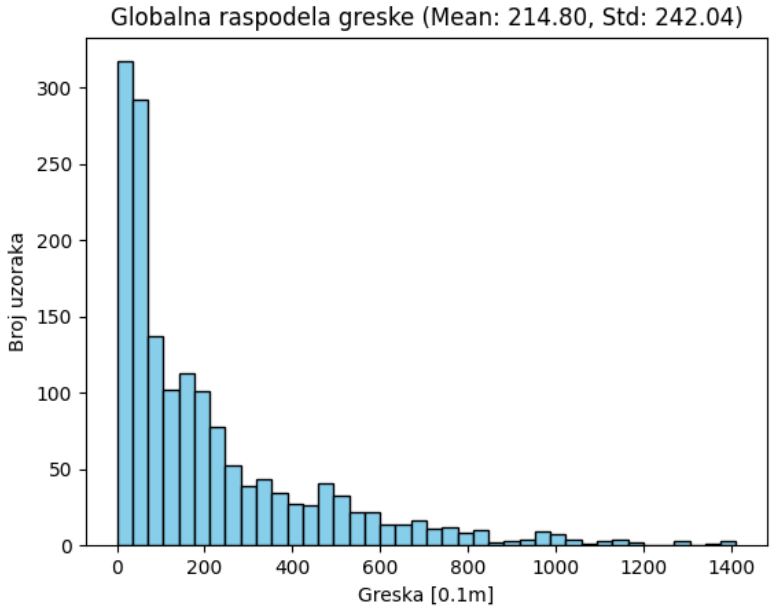
U proseku se po merenju detektuje samo 2.38 od 8 mogućih AP-ova, sto problem čini izrazito širokim — većina ulaznog vektora je nedetektovana.

3.2. Primena Expectation Maximization

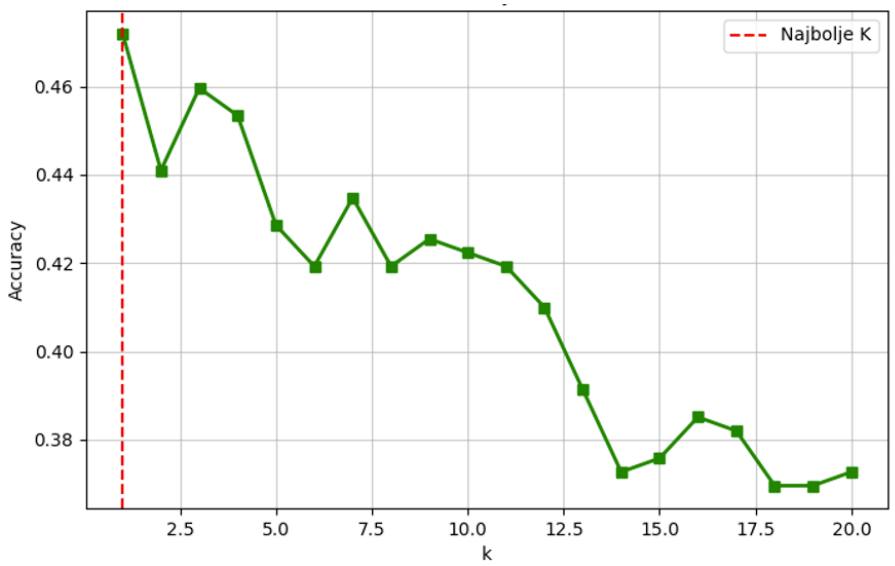
Pošto je većina merenja nepoznata to predstavlja veliki problem. Kako bi dobili više vrednosti za učenje ML metoda korišćena je Expectation Maximization metoda. Ovo smo radili pod pretpostavkom MAR(missing at random).



Može se videti da smo sada dobili raspodelu koja odgovara Gausovoj normalnoj raspodeli. Kada sada iskoristimo ovako modifikovane podatke pri kNN metodi dobijamo sledeće rezultate



Dobijamo srednju RMSE od 21,48m. Za vrednost tačnosti klasifikacije dobijamo sledeće vrednosti



Kao što se vidi sa grafika mi najbolju tačnost imamo kada je k jedan i onda iznosi 46%.

3.3. Zamena nepoznatih vrednosti

Pošto se pri primeni EM dobijaju lošiji rezultati nego kada se samo ignorišu nepoznate vrednost, dolazimo do zaključka da podaci ne nedostaju nasumično. Kod komercijalnih WiFi prijemnika prag osetljivosti je ~-100 dBm, ta pretpostavka se slaže sa merenjima koje smo dobili, maksimalna vrednost je bila -97 dBm.

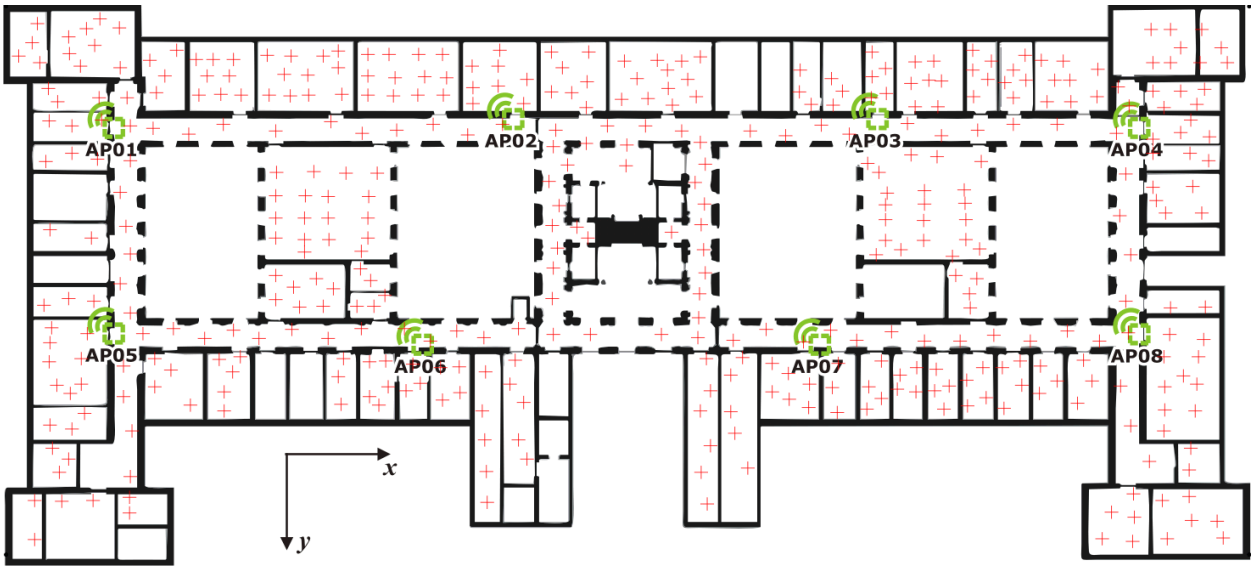
Tabela 3.1. Tačnost i RMSE pri zameni nepoznatih vrednosti kod SVM

Zamena nepoznatih vrednosti	Accuracy[%]	RMSE[0,1m]
-1000	52,57±2,11	124,33±10,14
-200	66,21±2,08	92,39±6,79
-110	66,67±2,19	84,79±4,87
-100	66,31±2,11	84,81±4,69
0	65,19±2,14	94,76±8,19
1000	50,24±1,97	131,15±10,24

Iz tabele se vidi da vrednost -110 daje najbolje rezultate, i kod drugih metoda se dobija da je -110 najbolja vrednost.

3.4. Segmentacija

Radi bolje tačnosti korišćena je segmentacija terena. Korišćena su dva načina segmentacije.



Slika 3.4.1. Mapa fakulteta sa označenim tačkama merenja

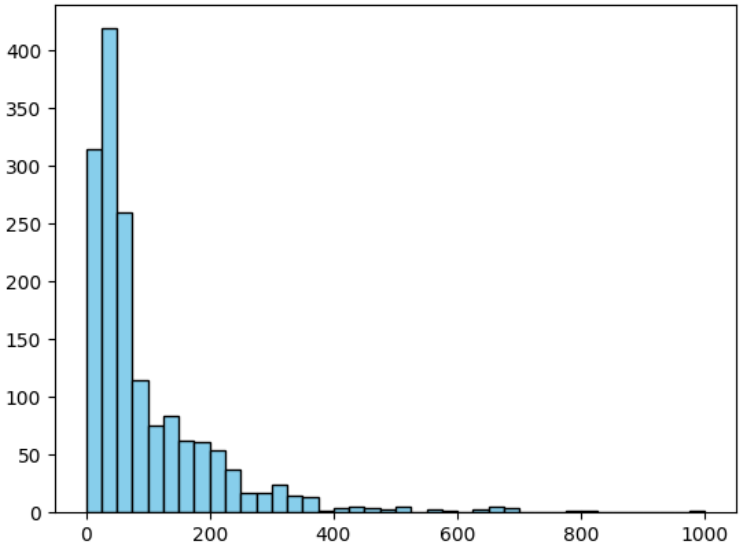
3.4.1. Prva segmentacija

Izvršena je podela terana na 28 zona. Podela je izvršena tako da se dve do tri sobe spajaju u jednu zonu, velike učionice u uglovima su stavljenje u posebne zone, svaki hodnik predstavlja svoju zonu, one imaju jednu veliku dimenziju što se pokazalo da pravi najveće greške, amfiteatri predstavljaju jednu zonu i velike stepenice prestavaljaju svoju zonu.



Slika 3.4.2. Segmantacija zona

Ova segmentacija je korišćena u kNN metodi. Dobijaju se sledeći rezultati.



Slika 3.4.3. Raspodela RMSE greške u 0.1m pri prvoj segmentaicji

Dobija se srednja RMSE greška od 9,875m sa standardnom devijacijom od 11,3m.

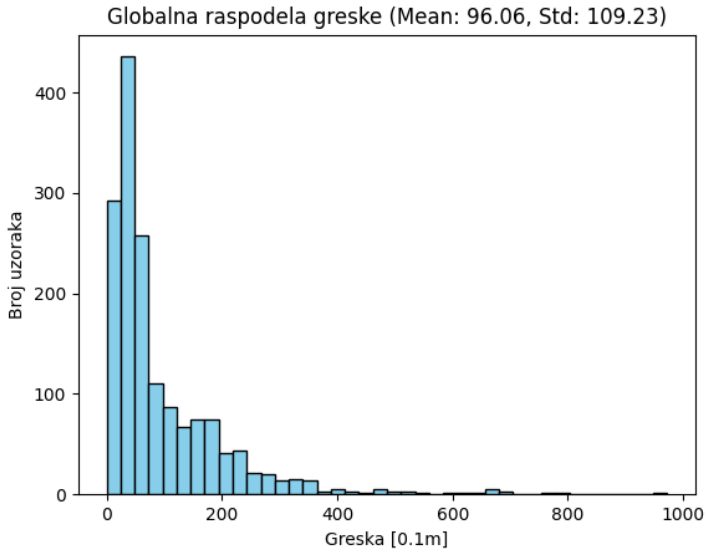
3.4.2. Druga segmentacija

Izvršena je segmentacija na 26 zona. Razlika u odnosu na prvu segmentaciju je što su zone hodnika ukinute i svaka zona kod hodnika je pripojila taj deo hodnika. Jedino je zona 26 ostala kao veliki izvor greške, pri proveri kvaliteta segmentacije zona korišćena je kNN tehnika.



Slika 3.4.2. Segmentacija zona

Dobija se sredni RMSE od 9,6m. Dobijaju se bolji rezultati pa je zato ova segmentacija izabrana za eksperiment.



Slika 3.4.3 Raspodela RMSE za drugu segmentaciju

3.5. QDA implementacija

Izvršena je implementacija QDA(Quadratic Discriminant Analysis) kao klasifikator i SVM kao regresor. Kao ostali parametri SVM su korišćeni oni koji su dali najbolje rezultate.

Tabela 3.5.1. Rezultati eksperimenta pri primeni QDA

Reg parametar QDA	Accuracy[%]	RMSE[0,1m]
0,5	58,05±2,09	95,32±4,84
0,1	55,76±2,02	92,8±4,81
0,01	52,54±1,88	93,69±4,71
0,2	56,23±2,06	92,81±4,81
0,05	54,92±1,97	93,08±4,74
0,15	56,02±2,02	92,72±4,84

U slučajaju kada se ne koristi QDA dobijaju se bolji rezultati 66,67 za tačnost i 84,47 za RMSE. U eksperimentu nije korišćen QDA.

4. Rezultati i diskusija

U ovom poglavlju će biti dati pregled rezultata koji su dobijeni korišćenjem različitih parametar tehnika mašinskog učenja, kao i prikazivanje najboljih rezultata. Za ocenu rezultata korišćena je 5 fold cross validation.

4.1. k-Nearest Neighbors rezultati

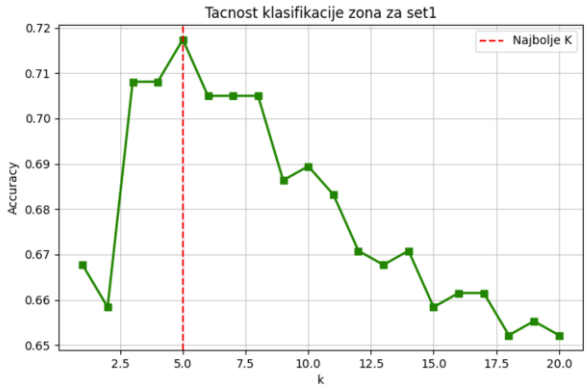
Eksperimenta je urađen jedanput. Korišćena je euklidska distanca. Različite zone imaju različite k(mogu imati vrednosti od 2 do 14). Rezultati RMSE za svih pet setova je sledeći:

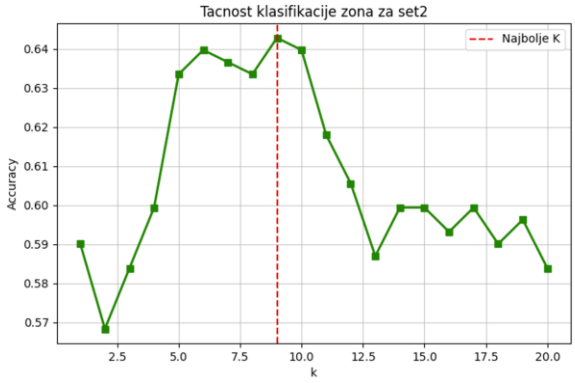
Tabela 4.1.1 Prikaz rezultata pri kNN metodi

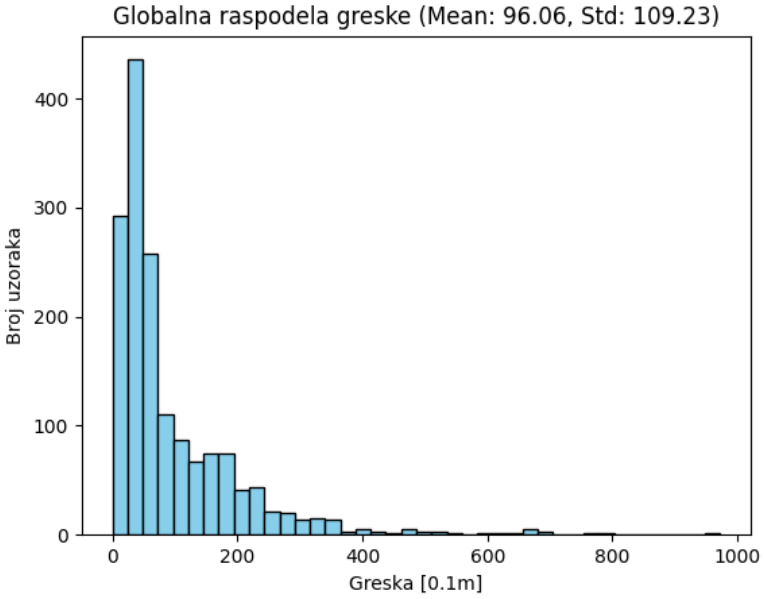
	Set1	Set2	Set3	Set4	Set5
RMSE[0,1 m]	82,86	100,38	94,88	94,82	89,68
Median[0,1 m]	50,93	55,08	54,17	51,56	51,46
Std[0,1 m]	87,77	107,05	105,81	116,71	95,68

Najbolji rezultati ima set1 dok najgori set2. Srednja vrednost RMSE je 92,4. Ove razlike rezultata se mogu pridodati nasumičnoj podeli podataka, šta ako u train skup nema mnogo predstavnika neke klase ta klase će direktno imati manji tačnost.

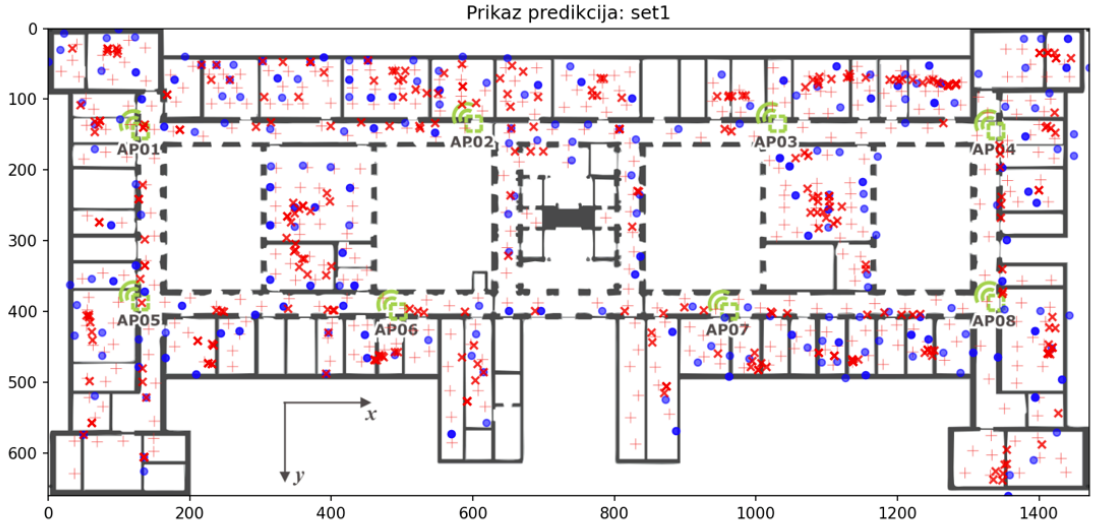
Tačnost klasifikacije ide od 64%(za set2) do 72%(za set1). Ostali setovi imaju sličnu tačnost.



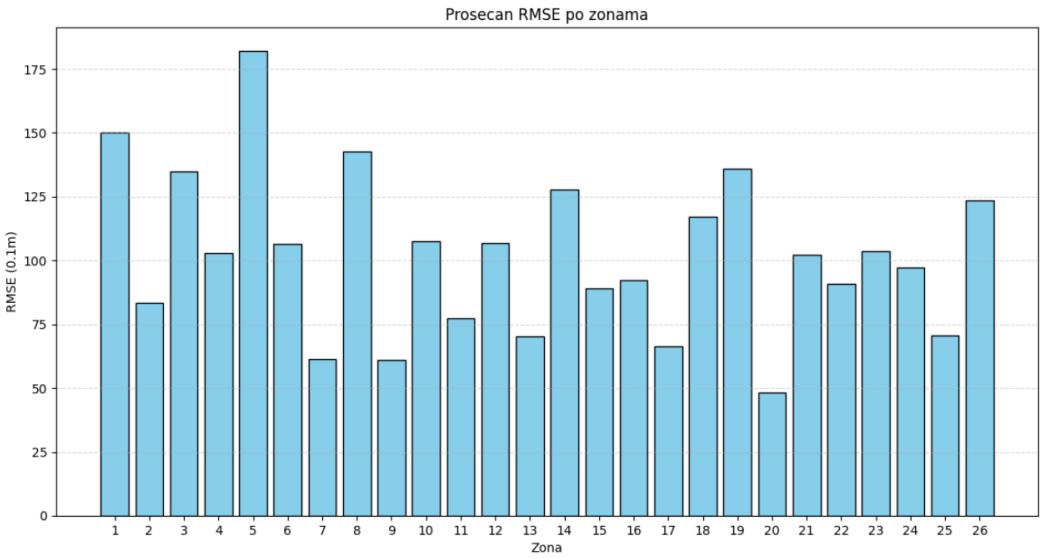




Na grafiku se vidi da preko 90% tačaka ima manje od 20m greške, dok preko polovine je stavljeno na manje od 6m. Najmanju tačnost imaju tačke koje pripadaju zonama 6, 16, 25, i 26.



Slika 4.1.1. Prikaz pozicioniranja tačaka test set1(plavi kružiči su stvarne koridnate tačaka, crveni iksovi su predikcije modela)



4.2. Neuralna mreža rezultati

4.2.1. Izbor klasifikatora

Testiran je binarni klasifikator. Korišćene su različite strukture neuralne mreže, kada ima jedan skriveni sloj pa do onih sa četiri. Najbolje su se pokazale mreže koje su najjednostavnije ona koja ima jedan hidden layer od 128 neurona je bila najbolja i imala je tačnost klasifikacije od 62.3%.

U svim mrežama je korišćena aktivaciona funkcija relu u hidden layeru a softmax u output layeru, korščen je optimizacija adam, loss fj je kros entropija, ove kombinacije su dale najbolje rezultate. Uveden je dodatna mera za regularizaciju dropout rate, u toku treninga određeni procenat neuraona ce se ugasiti, on može imati 4 vrednosti 0, 0.05, 0.1, 0.2.

Arhitektura neuralne mreže binarnih klasifikatora	Dropout Rate	Accuracy
8-32-16-1	0	59.19%
8-32-16-8-4-1	0.2	50%
8-32-16-8-4-1	0.1	51%
8-32-16-8-1	0.1	46%
8-16-1	0.1	54%
8-512-1	0.1	59%
8-128-1	0.2	62.3%

Kod višeklasnog klasifikatora korišćena je ista activaciju, loss i optimizaciju, kao i dropout rate. Ovde se pokazalo da su arhitekture koje su kompleksnije bolje, najbolja je 8-256-128-1.

Arhitektura neuralne mreže multiklas klasifikatora	Dropout Rate	Accuracy
8-128-80-50-32-1	0.2	60%
8-128-1	0.2	63.54%
8-32-16-8-4-1	0.1	61%
8-32-16-8-1	0.1	62.73%
8-16-1	0.1	65%
8-256-128-64-1	0.2	66.67%
8-256-128-64-32-1	0.2	63.85%

4.2.2. Arhitektura regresora

Koristi se isti optimizator i aktivaciona fj. kao i kod klasifikatora osim sto se u output layeru koristi linear i loss fj je RMSE, dropout rate je 0.2 testiranjem je utvrđeno da je najbolja struktura 8-256-128-2, pri pokretanju je korišćena 8-256-128-64-1 struktura za multiklasifa.

Arhitektura neuralne mreže regresije	Dropout Rate	RMSE(0.1m)
8-64-2	0.2	150
8-128-2	0.2	143
8-256-128-64-2	0.2	89.51
8-256-128-2	0.2	87.86

4.2.3. Izbor Regularizacije L2

Korišćene su različite vrednosti za L2 pokazalo se najbolje da ona bude 0.005. Kao što se vidi što je manja vrednost dobijaju se bolji rezultati.

L2	Accuracy	RMSE(0.1m)
0.1	53.03%	99.03
0.05	59.25%	94.66
0.01	63.74%	89.03
0.005	64.66%	88.99
0	63.2%	100.15

4.2.4. Izbor Batch size

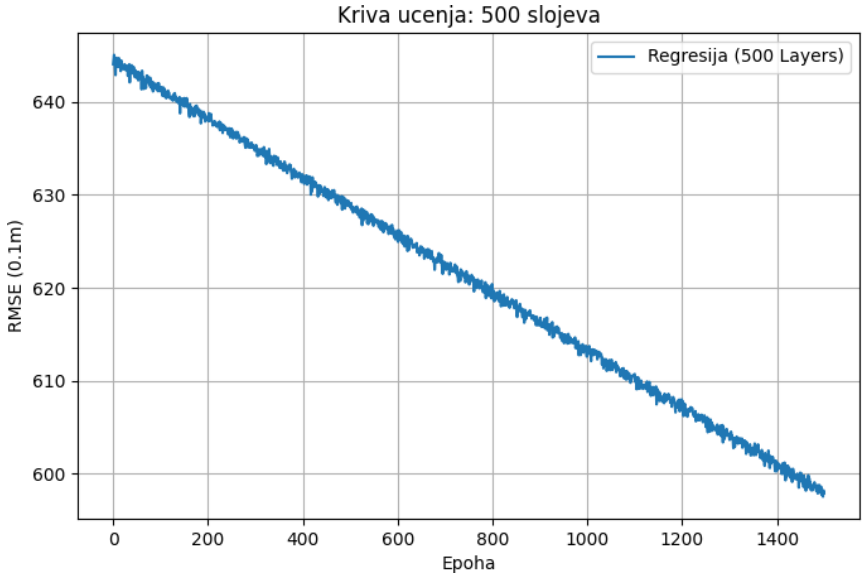
Korišćeno je sedam različitih batch size 4, 8, 16, 32, 48, 64, 128. Najbolji rezultati su dobijeni za batch size 64, važno je reći da su ovi rezultati dobijeni samo jednim pokretanjem eksperimenta. Vidi se da je vreme pokretanja kraće za veći batch size.

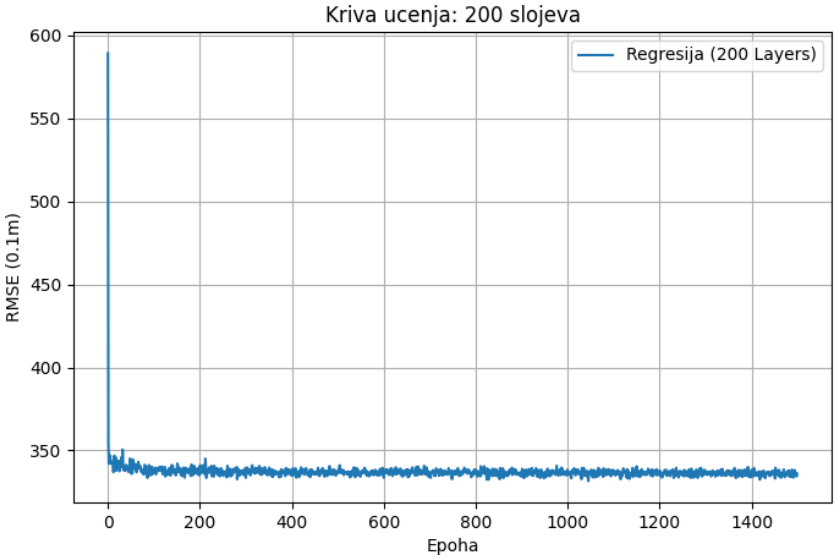
Batch size	Accuracy	RMSE(0.1m)	Vreme(s)
4	59.38%	97.14	753.52
8	63.91%	88.69	414.43
16	63.54%	88.92	279
32	65.03%	89.12	161
48	65.59%	88.92	113
64	66.15%	86.40	101
128	65.71%	87.92	86

4.2.5. Uticaj broja slojeva kod regresije na vreme izvršavanja

Vidi se da 2/3 sloja daju nabolje rezultate što se tiče vremena ispunjavanja i RMSE. Kada dođemo na 300 i više slojeva vidimo da model samo odlučuje da stavlja tačke na jedno mesto i da je prestao da uči.

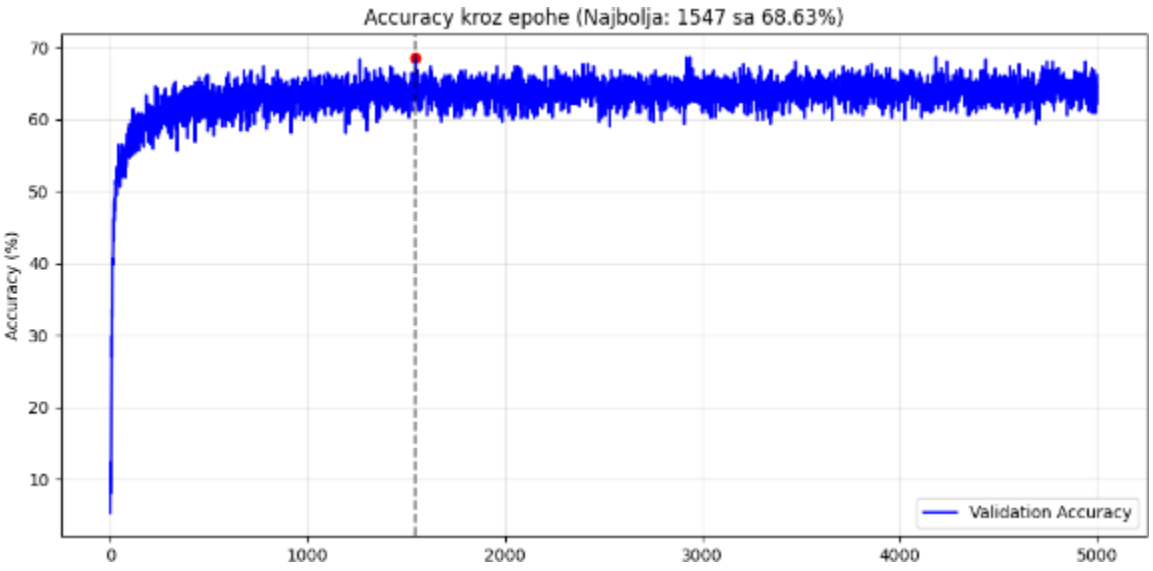
Broj hidden layera kod regresije	RMSE(0.1m)	Vreme(s)
1	109.6	93.6
2	86.3	100.52
3	89.54	101.96
50	118.82	227
100	323.05	355
200	322.93	713
300	604.06	1248
400	604.46	1610
500	604.06	2183



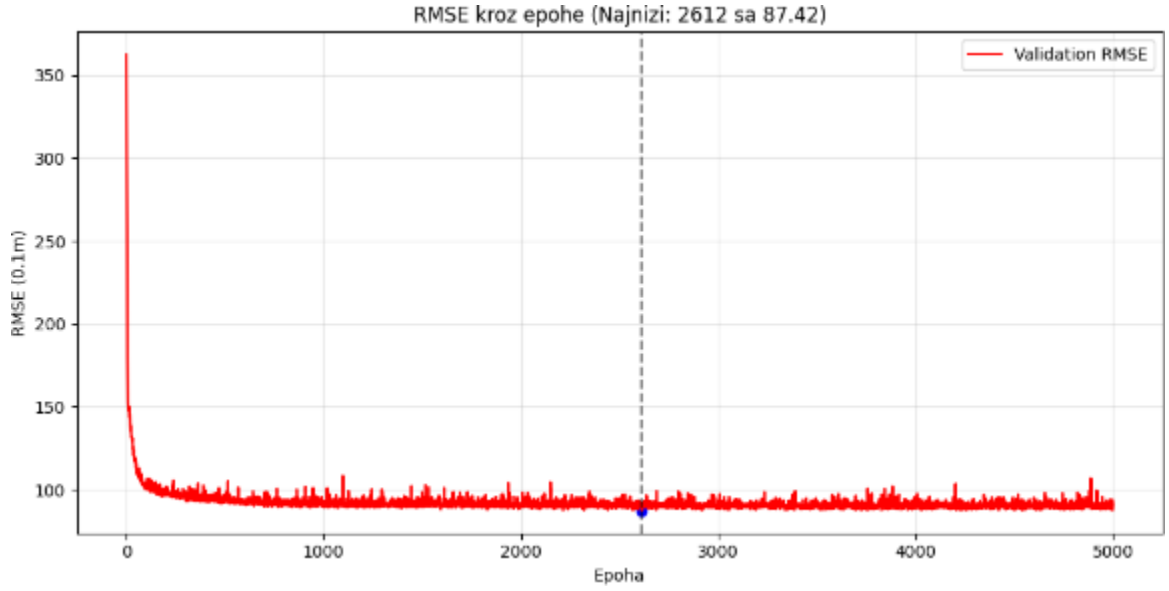


4.2.6. Rezultati

Testirano je kada dolazi do konvergencije vrednosti tačnosti. Vidi se da vrednosti nakon 1000 epoha konstantno variraju između 60 i 66%, a najbolja tačnost je 68.63%.

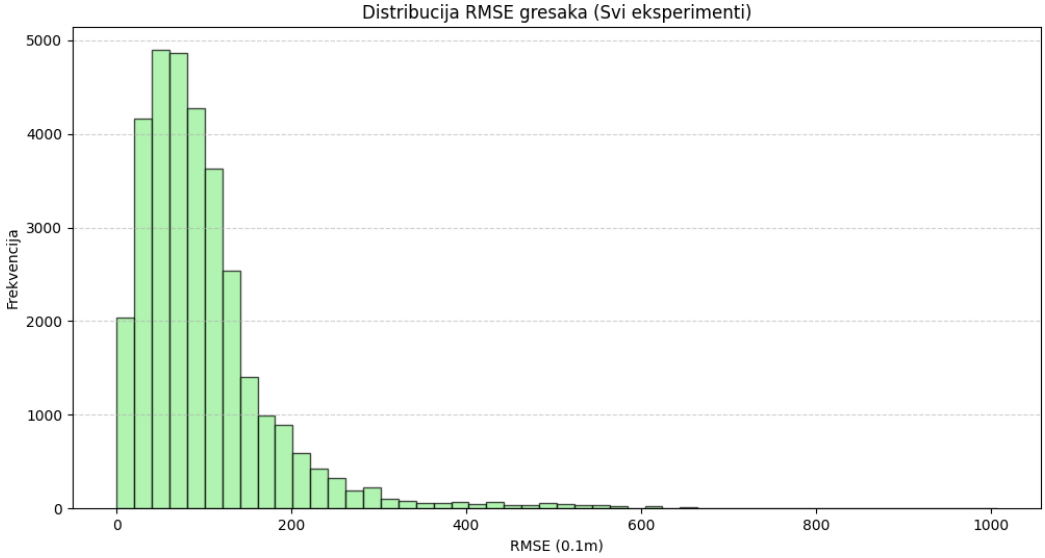


Kod regresije vidimo mnogo stabilniju situaciju, vrednosti već nakon hijadite epohe su stabilne i dobijamo, najbolju vrednost RMSE od 87.42.

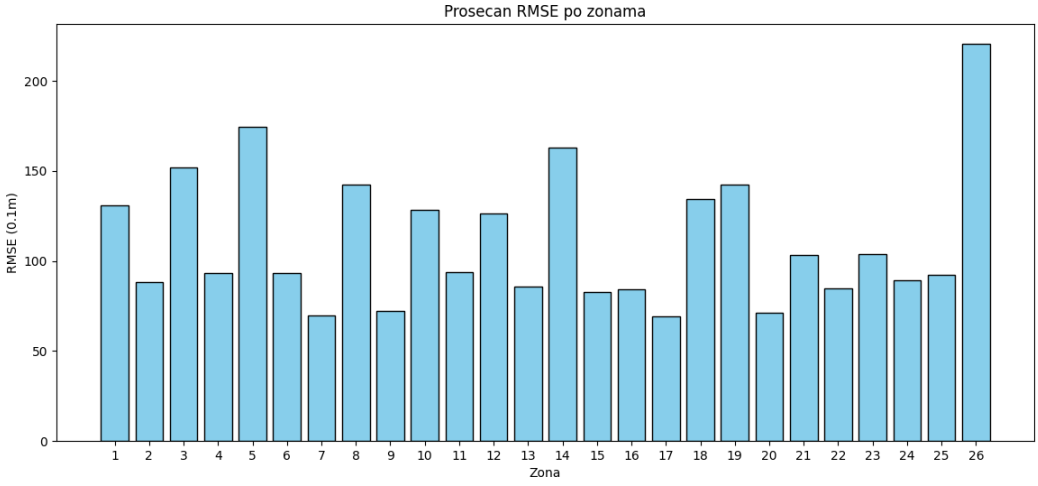


Za dobijene konačne rezultate korišćeno je 1000 epoha po iteraciji modela, 20 puta je pokrenut ceo eksperiment, 20 puta je izvršena 5 kros validacija. Korišćene su strukture NN mreže koje su dale najbolje rezultate, za višeklasni kalsifikator to je 8-256-128-64-1, a 8-256-128-2 za regresiju. Korišćena je relu aktivaciona funkcija u sakrivenim slojevima a linerna u

izlaznom sloju regresija a softmax u izlaznom sloju klasifikatora, dropout rate je 0.2, L2 regularizacije je 0.005 i stavljen je batch size od 64.



Kod histograma RMSE vidi se da se preko 80% vrednosti greške nalazi ispod 20m, a preko 50% ispod 10m. Vidi se da ima jako malo visokih vrednost izna 60m ih ima samo nekoliko



Ovaj grafik predstavlja srednju vrednost svih grešaka po zonama. Najveće greške imamo u 5,14 i 26 zoni. Dobija se prosečna tačnost klasifikatora od 65.27%, prosečan RMSE regresije je 8.79m. Medijalna RMSE je 8.12m a std je 5.43.

4.3. Support Vector Machine

4.3.1. Izbor regularizacije

Rezultati su dobijeni pokretanjem eksperimenta 100 puta: Kao kernel se koristii rbf, korišćen clipping tako da se ukoliko tačka dobije kordinate van dodeljene zone ona stavi na ivicu dodeljenje zone. Najboljio rezultati se dobijaju kada se stavi regularizacija za regresiju da bude 700 a 100 za klasifikaciju

Regularizacija kod regresije	Regularizacija kod klasifikatora	Accuracy[%]	RMSE[0,1m]
100	0,01	14,81±1,93	332±4,6
100	10	67,2±2,17	86,99±4,93
100	1000	64,64±2,17	88,17±5,07
100	50	67,09±2,18	86,36±4,92
0,01	100	66,75±2,18	126±5,09
0,1	100	66,75±2,18	125,1±4,95
10	100	66,75±2,18	92,7±4,46
100	100	66,75±2,18	85,94±4,76
200	100	66,75±2,18	85,14±4,76
300	100	66,75±2,18	84,97±4,79
400	100	66,75±2,18	84,84±4,8
500	100	66,75±2,18	84,78±4,82
600	100	66,75±2,18	84,73±4,83
700	**100**	**66,75±2,18**	**84,7±4,84**
700	200	66,17±2,17	85,04±4,9

4.3.2. Izbor kernela

Korišćeni su parametri 700 za regularizaciju regresije a 200 za regularizaciju klasifikacije. VIdi se da se najbolji rezultati dobijaju kada se korist rbf kod regresije i klasifikacije.

Kernel regresije	Kernel klasifikacije	Accuracy[%]	RMSE[0,1m]
linear	rbf	66,17±2,17	107,91±4,15
poly	rbf	66,17±2,17	95,61±4,54
sigmoid	rbf	66,17±2,17	136,5±6,36
rbf	linear	63,44±2,25	86,78±5,14
rbf	poly	65,57±2,24	86,18±5,08
rbf	sigmoid	47,35±2,5	105,9±6,32

4.3.2. Izbor gamme

Gamma kod regresije	Gamma kod klasifikacije	Accuracy[%]	RMSE[0,1m]
auto	scale	66,75±2,18	84,7±4,84
scale	auto	66,75±2,18	84,7±4,84

4.3.3. Izbor clippinga

Kada se umesto uz ivicu zone tačke stavljaju u centar te zone dobijaju se lošiji rezultati.

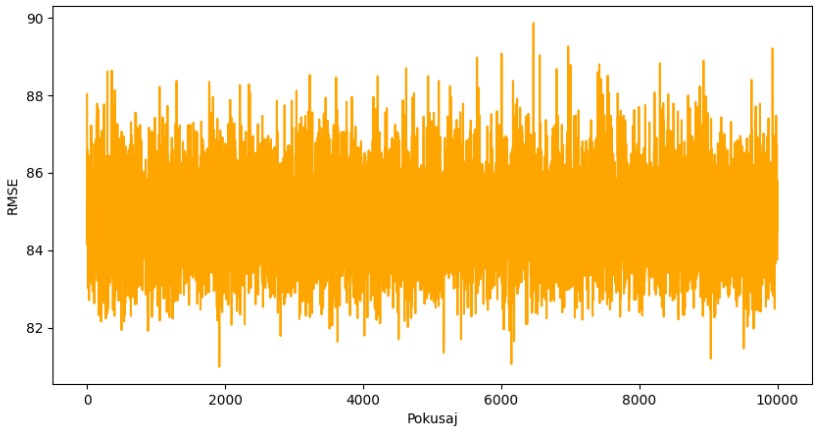
Accuracy[%]	RMSE[0,1m]
66,28±2,38	99,33±5,68

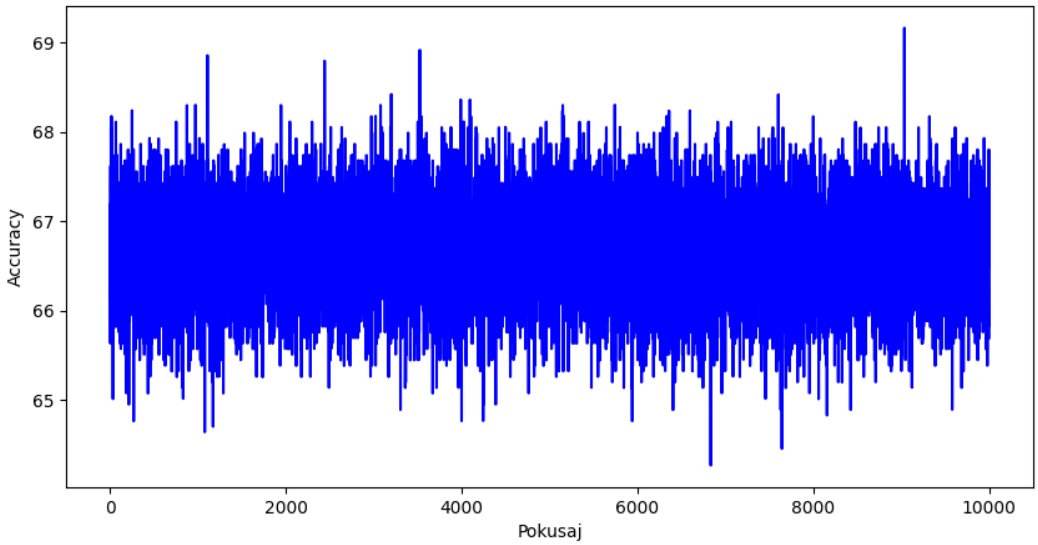
4.3.4. Rezultati

Sledeći parametri su korišćeni pri pokretanju eksperimenta:

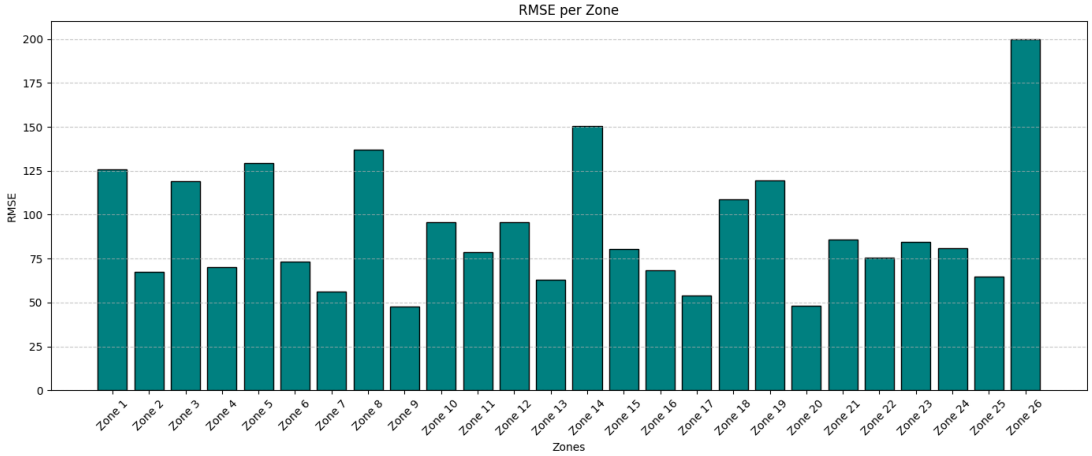
- Regularizacija klasifikatora je 100
- Regularizacija regresora je 700
- Kernel je rbf
- Gamma je scale
- Clippingom se tačke stavljaju na ivicu zone
- Eksperiment je izvršen 10.000 puta
- Nepoznate vrednosti su zamenjene sa -110
- Korišćen je 5 fold cross validation

Accuracy[%]	RMSE[0,1m]
66,67±2,19	84,79±4,87

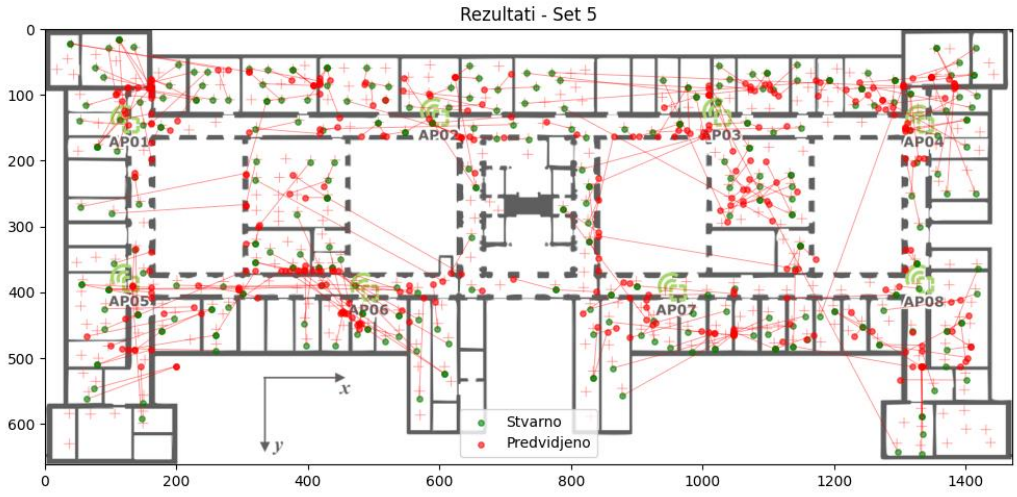




Po zonama se dobija sledeća tačnost:



Kao što se vidi sad grafika RMSE po zonama najmanje greške imamo u zonama 2, 4, 6, 7, 13, 15, 16, 20 i 25. Vidmo da su najmanje greške u zonama gde se nalaze pristupne tačke. Najveća greška je u 26. zoni.



Jedna jako interesantna stvar je što i na 50 pokretanja eksperimenta i na 10.000 dobijaju se isti rezultati. Model je dostigao maksimum koji može da izvuče iz ovako postavljenog eksperimenta.

4.4. Diskusija

Dobijeni rezultati ukazuju na različite performansanse primenjenih modela mašinskog učenja za potrebe lokalizacije unutar posmatranog prostora. Analizom RMSE metrike i tačnosti klasifikacije zona, uočava se da SVM (Support Vector Machine) model trenutno dominira u pogledu preciznosti i stabilnosti. SVM se pokazao izuzetno efikasnim u pronalaženju optimalne hiperravni za razdvajanje zona, čak i sa ograničenim skupom trening podataka, što ga čini idealnim rešenjem za trenutnu konfiguraciju sistema.

Međutim, primetno je da SVM model "udara u plafon" svojih mogućnosti. Bez obzira na dalje podešavanje hiperparametara ili manja proširenja skupa podataka, marginalna dobit u tačnosti je zanemarljiva. Ovo ukazuje na činjenicu da SVM, kao algoritam zasnovan na pronalaženju podržavajućih vektora, dostiže tačku zasićenja kada modeluje kompleksne nelinearne zavisnosti RSSI signala u dinamičkom okruženju. Njegova struktura postaje limitirajući faktor koji sprečava dalje smanjenje RMSE vrednosti.

Sa druge strane, neuronske mreže (NN) pokazuju potpuno drugačije ponašanje. Iako trenutno ne nadmašuju SVM, one poseduju inherentni potencijal za bolje modelovanje visoko nelinearnih prostora. Neuronske mreže su izuzetno "gladne" podataka; njihova sposobnost da kroz duboke slojeve uče složene šablone iz RSSI distribucije zahteva drastično veći korpus merenja. Trenutni nedostatak podataka sprečava NN da ostvare svoju punu prediktivnu moć. Hipotetički posmatrano, ukoliko bi se skup podataka proširio sa stotina na desetine hiljada uzoraka, neuronske mreže bi verovatno prevazišle trenutne performanse SVM modela. Dok SVM model "stagnira" zbog svoje rigidne matematičke strukture, neuronske mreže bi tek tada mogle da iskoriste svoj kapacitet za generalizaciju i postignu preciznost koju je trenutno nemoguće dostići standardnim metodama.

Zaključno, izbor modela zavisi od dugoročne strategije: SVM pruža trenutnu optimalnost i stabilnost za postojeći skup podataka, dok neuronske mreže predstavljaju investiciju u sistem koji bi, uz kontinuirano prikupljanje podataka, dugoročno bio superiorniji i precizniji u lokalizaciji.

5. Zaključak

U ovom radu sprovedena je komparativna analiza algoritama mašinskog učenja — kNN, neuronskih mreža, SVM i QDA — u cilju preciznog pozicioniranja korisnika na osnovu RSSI signala WiFi pristupnih tačaka. Kroz eksperimentalnu fazu, fokus je bio na obradi nepotpunih podataka pomoću Expectation-Maximization algoritma, primeni tehnika prostorne segmentacije i optimizaciji parametara modela kako bi se minimizovala RMSE greška u realnim uslovima.

Budući radovi mogu biti usmereni na proširenje baze podataka radi prevazilaženja ograničenja trenutnih nelinearnih modela, poput neuronskih mreža, čime bi se omogućilo njihovo punije iskorišćenje. Takođe, dalja unapređenja mogu uključiti implementaciju hibridnih modela koji kombinuju prednosti više algoritama, uvođenje dinamičkih metoda za praćenje promena u signalu usled kretanja korisnika, kao i optimizaciju broja pristupnih tačaka radi povećanja energetske efikasnosti sistema bez gubitka preciznosti.